

什么是 RAG？

RAG (Retrieval - Augmented Generation) 检索增强生成，是一种把大语言模型的生成能力与外部知识库结合起来的技术。传统大模型只能依据训练时见过的数据回答，对私有文档、最新资讯一无所知，而且容易一本正经地编造答案 (幻觉)。

RAG 的思路很简单：

提问时，先到你的知识库中检索最相关的片段，把片段和问题一起交给模型，并规定它只依据片段作答、标明出处。这样既能让模型回答私有资料里的问题，也能大幅降低幻觉。

混合检索为什么更好？

本系统使用混合检索：同时运行 BM25

关键词检索与向量语义检索两条通道。BM25 擅长精确匹配术语、编号，比如“GB / T 9704”或“RNN”。向量检索擅长理解同义改写，例如问“怎么防止模型说胡话”也能找到写“缓解幻觉”的段落。

两条通道各自返回前 100 名，再用

RRF（倒数排名融合）把两个榜单合并：某个片段只有在至少一条通道中排名足够靠前才能进入最终结果，两条通道都靠前的片段分数最高。

引用与页码： 让答案可溯源

解析 P D F

时，程序逐页提取文字并记录页码。分块时每一块都记住自己来自第几页，如果一块横跨两页，会标注为“ 3 - 4 ”。

回答生成后，程序扫描输出中的 [1] [2] 等引用编号，整理成来源清单：文档名 + 页码 + 原文摘要。点击来源卡片即可定位到对应片段，人工核对答案是否忠于原文 —— 这是 R A G 相比微调的核心优势之一。